ARSITEKTUR & PIPELINE MATCHING RE-MATCH (END-TO-END)

Sistem Pencocokan, Deduplikasi & Rekonsiliasi Data Entitas Multi-Tahap (WLS + Multi-Tier Guardrails)

TAHAP 1 — Data Ingestion, Smart Entity Extraction & Deduplikasi Input

1. Input & Reference Ingestion

- Membaca file CSV/Excel secara chunking
- Mapping kolom manual & AI Auto-Match
- Penyimpanan dataset ke DB lokal/Docker

2. Smart Entity Extraction ([GEN] Atribut)

- [GEN] Nama Inti: Ekstraksi nama tanpa badan usaha
- [GEN] Bentuk Badan Usaha: PT, CV, UD, Fa, Koperasi
- [GEN] Alamat Terstandardisasi: Ejaan & singkatan

3. Input Deduplication Analysis

- Deteksi duplikasi internal baris input
- Pemisahan baris unik vs duplikat input
- Mencegah pemborosan komputasi matching

Record Bersih & Terstandarisasi

TAHAP 2 — Normalisasi Nilai & Dual-Engine Indexing (Blocking Phase)

1. Deep Value Normalizer

- Case folding (lowercase), trim spasi ganda
- Normalisasi karakter non-alfanumerik
- Substitusi sinonim & singkatan baku (Jl. -> Jalan, dll.)

2. Meilisearch Indexing & Reusable Cache

- Indeks dataset referensi ke search engine terisolasi
- Locking mechanism (Cache lock) untuk reuse index
- Pengelompokan atribut pencarian cepat (col_hash)

Indeks Referensi Siap

TAHAP 3 — Candidate Generation: Multi-Search & Filtering Top-N

Multi-Search Execution via Meilisearch

- Chunking batch pencarian (250 - 500 records/chunk)
- Typo-tolerant N-Gram & Prefix Querying
- Mempersempit jutaan kombinasi menjadi Top-N kandidat

Top-N Candidate Extraction (N = 3 s.d. 5)

- Mengambil kandidat teratas paling relevan per baris input
- Memastikan tidak ada perbandingan O(M x N) yang lambat
- Menyusun pasangan kandidat (Input_i, Ref_Candidate_j)

Pasangan Kandidat (Candidate Pairs)

TAHAP 4 — Weighted Levenshtein Similarity (WLS) & Multi-Algorithm Scoring

Jaro-Winkler	Levenshtein / Token Set	Normalized Exact	Normalized Exact
Nama Perusahaan / Inti	**Alamat Terstandardisasi**	**Bentuk Badan Usaha**	**Kode Wilayah / Kab-Kota**
Toleransi typo ejaan nama	Toleransi singkatan jalan	Validasi legalitas (PT/CV)	Validasi batas wilayah spasial

RUMUS UMUM WLS:

```
Skor Total = (Skor_NamaInti * W_nama) + (Skor_Alamat * W_alamat) + (Skor_Badan * W_badan) + (Skor_Wilayah * W_wilayah)
```

Skor WLS Gabungan & Skor Parsial

TAHAP 5 — Multi-Tier Verification Guardrails & Decision Tree (Preset Engine)

1. Preset Konstruksi

- Ambang: >=90% Auto, 80-89% Reviu
- Verifikasi Kota 100% (Exact)
- Syarat Ganda: Nama 100% & Alamat 100%
- Cek status_perusahaan Aktif (is_active)

2. Preset Standar / Umum

- Ambang: >=90% Auto, 75-89% Reviu
- Pembobotan proporsional seimbang
- Guardrails urutan standar kolom
- Auto-downgrade jika rule parsial gagal

3. Mode Kustom Penuh

- Ambang batas disesuaikan manual
- Penyesuaian bobot bebas per mapping
- Aturan verifikasi fleksibel per industri
- Custom tolerance thresholds

Klasifikasi (Matched / Need Review / Unmatched)

TAHAP 6 & 7 — Post-Match Clustering (Case Groups) & Human-in-the-Loop Review Hub

Deteksi Anomali & Pengelompokan Kasus (Case Groups)

- GEO_LOCATION_CONFLICT: Nama & Alamat mirip, beda kode kab/kota
- LEGAL_FORM_CONFLICT: Nama mirip tapi beda bentuk badan (PT vs CV)
- FIELD_CONFLICT: Perbedaan pada atribut kolom pendukung
- SIMILAR_NAME_REVIEW: Kemiripan nama di ambang batas abu-abu

Human-in-the-Loop Hub (Tab Reviu Hasil)

- Verifikasi 1-Klik / Bulk Decision pada kelompok homogen
- Perbandingan berdampingan (Side-by-side) nilai input vs referensi
- Keputusan tegas: [Terima Match] atau [Tandai Unmatched]
- Audit trail lengkap tersimpan ke database

Keputusan Final Tervalidasi

TAHAP 8 — Output & Intent-Based Export (Hasil Akhir)

1. Pemutakhiran Master
Data siap sinkronisasi ke tabel master
(Record terverifikasi + Data baru)

2. Laporan Audit Lengkap
Seluruh pasangan record, skor WLS,
bukti verifikasi, dan riwayat reviu

3. Sisa Perlu Reviu
Daftar anomali dan kasus pending
untuk tindak lanjut tim verifikator

ALGORITMA RUNNING & DECISION TREE PER KONFIGURASI

Mekanisme Pemilihan Kandidat, Pembobotan WLS & Logika Percabangan Keputusan Preset Konstruksi

BAGIAN A — Alur Pemilihan Kandidat Cepat (Candidate Generation Pipeline)

1. Input Stream
Record input dibaca per-chunk (500 baris).
Dilakukan normalisasi nama & alamat.

→

2. Mandatory Check
Jika ada kolom Strict (NIK/NPWP):
Langsung filter via Exact Index Blocking.

→

3. Meilisearch Query
Pencarian fuzzy string & N-gram pada
index referensi untuk ranking relevansi.

→

4. Top-N Selection
Mengambil Top-3 kandidat tertinggi.
Pasangan dikirim ke WLS Scorer.

SKEMA PEMBOBOTAN WLS PRESET KONSTRUKSI (TOTAL: 100%):

1. [GEN] NAMA INTI	`Bobot: 55% (0.55)`	Fuzzy WLS (Jaro-Winkler / Levenshtein) • Toleransi typo nama
2. ALAMAT TERSTANDARDISE	`Bobot: 30% (0.30)`	Fuzzy WLS (Levenshtein) • Toleransi singkatan jalan
3. [GEN] BADAN USAHA	`Bobot: 10% (0.10)`	Normalized Exact Match (1.0 / 0.0) • Validasi PT, CV, UD
4. KODE KAB/KOTA	`Bobot: 5% (0.05)`	Normalized Exact Match (1.0 / 0.0) • Validasi batas wilayah

BAGIAN B — Decision Tree Flowchart: Evaluasi Bertingkat Preset Konstruksi

START: Compare Record Pair

EVALUASI 1: Apakah Skor WLS >= 90%?
Memeriksa skor kemiripan berbobot secara agregat

- TIDAK (<90%) → **Pemeriksaan Ambang: Skor 80% - 89%?**
  Zona abu-abu yang memerlukan verifikasi analis
  - YA → **MANUAL CHECK**
    NEED REVIEW
    Keputusan ditentukan oleh Data Analyst
  - TIDAK (<80%) → **UNMATCH**
    INSERT REFERENCE
    Record baru/berbeda, masuk ke referensi
- YA (>=90%) → **EVALUASI 2: Kemiripan Kota == 100%?**
  Pemeriksaan variabel pendukung wilayah spasial
  - YA → **MATCH**
    DROP DUPLIKAT
    Duplikat terkonfirmasi dari referensi aktif
  - TIDAK (<100%) → **EVALUASI 3: Nama 100% DAN Alamat 100%?**
    Pemeriksaan syarat ganda identitas fisik
    - TIDAK → **UNMATCH**
      INSERT REFERENCE
      Data cabang baru, masuk ke referensi
    - YA (100% & 100%) → **EVALUASI 4: Referensi.is_active == 1?**
      Validasi status aktif (kolom status_perusahaan)
      - YA (Aktif) → **MATCH**
        DROP DUPLIKAT
        Duplikat referensi aktif, record input di-drop
      - TIDAK (Tutup/Non-Aktif) → **UNMATCH**
        INSERT REFERENCE
        Referensi non-aktif, masuk entitas baru

RINGKASAN HASIL AKHIR (TERMINAL NODES):

MATCH (DROP record):
Data dianggap duplikat sah dari referensi aktif. Record input diabaikan/dihapus agar master data tetap bersih.

UNMATCH (INSERT record to Reference):
Data dianggap entitas baru / cabang berbeda / pengganti referensi tutup. Dimasukkan ke tabel Referensi.

MANUAL CHECK (User decides):
Data masuk zona ambang sedang (80% - 89%). Keputusan verifikasi diserahkan kepada User / Data Analyst di Review Hub.