ARSITEKTUR & PIPELINE MATCHING RE-MATCH (END-TO-END)

Sistem Pencocokan, Deduplikasi & Rekonsiliasi Data Entitas Multi-Tahap (WLS + Multi-Tier Guardrails)

TAHAP 1 — Data Ingestion, Smart Entity Extraction & Deduplikasi Input

1. Input & Reference Ingestion

- Membaca file CSV/Excel secara chunking
- Mapping kolom manual & AI Auto-Match
- Penyimpanan dataset ke DB lokal/Docker

2. Smart Entity Extraction ([GEN] Atribut)

- [GEN] Nama Inti: Ekstraksi nama tanpa badan usaha
- [GEN] Bentuk Badan Usaha: PT, CV, UD, Fa, Koperasi
- [GEN] Alamat Terstandardisasi: Ejaan & singkatan

3. Input Deduplication Analysis

- Deteksi duplikasi internal baris input
- Pemisahan baris unik vs duplikat input
- Mencegah pemborosan komputasi matching

Record Bersih & Terstandarisasi

TAHAP 2 — Normalisasi Nilai & Dual-Engine Indexing (Blocking Phase)

1. Deep Value Normalizer

- Case folding (lowercase), trim spasi ganda
- Normalisasi karakter non-alfanumerik
- Substitusi sinonim & singkatan baku (Jl. -> Jalan, dll.)

2. Meilisearch Indexing & Reusable Cache

- Indeks dataset referensi ke search engine terisolasi
- Locking mechanism (Cache lock) untuk reuse index
- Pengelompokan atribut pencarian cepat (col_hash)

Indeks Referensi Siap

TAHAP 3 — Candidate Generation: Multi-Search & Filtering Top-N

Multi-Search Execution via Meilisearch

- Chunking batch pencarian (250 - 500 records/chunk)
- Typo-tolerant N-Gram & Prefix Querying
- Mempersempit jutaan kombinasi menjadi Top-N kandidat

Top-N Candidate Extraction (N = 3 s.d. 5)

- Mengambil kandidat teratas paling relevan per baris input
- Memastikan tidak ada perbandingan O(M x N) yang lambat
- Menyusun pasangan kandidat (Input_i, Ref_Candidate_j)

Pasangan Kandidat (Candidate Pairs)

TAHAP 4 — Weighted Levenshtein Similarity (WLS) & Multi-Algorithm Scoring

Jaro-Winkler	Levenshtein / Token Set	Normalized Exact	Normalized Exact
Nama Perusahaan / Inti	**Alamat Terstandardisasi**	**Bentuk Badan Usaha**	**Kode Wilayah / Kab-Kota**
Toleransi typo ejaan nama	Toleransi singkatan jalan	Validasi legalitas (PT/CV)	Validasi batas wilayah spasial

RUMUS UMUM WLS:

```
Skor Total = (Skor_NamaInti * W_nama) + (Skor_Alamat * W_alamat) + (Skor_Badan * W_badan) + (Skor_Wilayah * W_wilayah)
```

Skor WLS Gabungan & Skor Parsial

TAHAP 5 — Multi-Tier Verification Guardrails & Decision Tree (Preset Engine)

1. Preset Konstruksi

- Ambang: >=90% Auto, 80-89% Reviu
- Verifikasi Kota 100% (Exact)
- Syarat Ganda: Nama 100% & Alamat 100%
- Cek status_perusahaan Aktif (is_active)

2. Preset Standar / Umum

- Ambang: >=90% Auto, 75-89% Reviu
- Pembobotan proporsional seimbang
- Guardrails urutan standar kolom
- Auto-downgrade jika rule parsial gagal

3. Mode Kustom Penuh

- Ambang batas disesuaikan manual
- Penyesuaian bobot bebas per mapping
- Aturan verifikasi fleksibel per industri
- Custom tolerance thresholds

Klasifikasi (Matched / Need Review / Unmatched)

TAHAP 6 & 7 — Post-Match Clustering (Case Groups) & Human-in-the-Loop Review Hub

Deteksi Anomali & Pengelompokan Kasus (Case Groups)

- GEO_LOCATION_CONFLICT: Nama & Alamat mirip, beda kode kab/kota
- LEGAL_FORM_CONFLICT: Nama mirip tapi beda bentuk badan (PT vs CV)
- FIELD_CONFLICT: Perbedaan pada atribut kolom pendukung
- SIMILAR_NAME_REVIEW: Kemiripan nama di ambang batas abu-abu

Human-in-the-Loop Hub (Tab Reviu Hasil)

- Verifikasi 1-Klik / Bulk Decision pada kelompok homogen
- Perbandingan berdampingan (Side-by-side) nilai input vs referensi
- Keputusan tegas: [Terima Match] atau [Tandai Unmatched]
- Audit trail lengkap tersimpan ke database

Keputusan Final Tervalidasi

TAHAP 8 — Output & Intent-Based Export (Hasil Akhir)

1. Pemutakhiran Master
Data siap sinkronisasi ke tabel master
(Record terverifikasi + Data baru)

2. Laporan Audit Lengkap
Seluruh pasangan record, skor WLS,
bukti verifikasi, dan riwayat reviu

3. Sisa Perlu Reviu
Daftar anomali dan kasus pending
untuk tindak lanjut tim verifikator